


بسم الله الرحمن الرحيم

گزارش پروژه پایانی هوش محاسباتی – دکتر عبادزاده


پرهام رحیمی – ۹۵۳۱۰۳۱

ورودی:

با استفاده از `data_generator.py` می توان داده هایی به تعداد و ابعاد و تعداد کلاس های دلخواه و با توزیع نرمال و به مرکز های رندوم و به شعاع دلخواه تولید کرد. خروجی آن در دو فایل آموزش و تست با فرمت CSV، با نام دلخواه ذخیره می گردد. فایل تست به صورت پیش فرض با همان مشخصات فایل آموزش منتهی با ۱۰ برابر تعداد نقاط آن تولید می گردد. به عنوان مثال شکل زیر نمودار داده های تولید شده توسط این برنامه با سایز خوشه ی ۵۰ و شعاع نرمال ۱ و تعداد خوشه ۵ و به صورت دو بعدی است:



و شکل زیر نمودار داده های تولید شده توسط این برنامه با سایز خوشه ی ۱۰۰ و شعاع نرمال ۱,۵ و تعداد خوشه ۲ و به صورت دو بعدی است:




البته برنامه می تواند با سایر داده ها که به فرمت CSV هستند نیز کار کند.

الگوریتم:

در این پروژه شبکه عصبی RBF پیاده سازی شده که به وسیله ی الگوریتم تکاملی (ES) آموزش می یابد.

پیاده سازی:



شبکه عصبی به صورت فوق فرض می شود. هر کدام از ورودی ها (x_i ها) بردار یست به طول بعد ورودی. و این n ورودی بر روی m مرکز مپ می شوند. و در نهایت خروجی با توجه به آن ها به دست می آید.

برای الگوریتم تکاملی از ابزار ¹Deap استفاده شده است. هر individual متشکل از {تعداد مرکزها \times تعداد بعد های ورودی + تعداد مرکزها} ژن است. که در واقع {تعداد مرکزها \times تعداد بعد های ورودی} ژن اول

¹ https://deap.readthedocs.io/en/master/examples/es_fctmin.html

نشان دهنده مختصات مرکز خوشه ها است و {تعداد مرکزها} ژن بعدی نشان دهنده طول شعاع هر کدام از خوشه ها به ترتیب است. برای آنکه ابزار Deap استفاده شده بتواند به درستی و مطابق با خواست ما کار کند تابع `error()` مطابق با زیر نوشته شد و به جای تابع `evaluate` این ابزار به آن ورودی داده شد:

```
def error(ind):
    if classification:
        G = []
        W = []
        V = np.array(ind[0:-number_of_groups]).reshape([number_of_groups, dimension])
        for point in train:
            g_row = []
            for group_num in range(number_of_groups):
                difference = np.array(point[:-1] - V[group_num])
                pow = -ind[number_of_groups * dimension + group_num] * (np.matmul(np.transpose(difference), difference))
                element = np.math.e ** pow
                g_row.append(element)
            G.append(g_row)
        G = np.array(G)
        W = np.array(W)
        Gt = np.transpose(G)
        y = np.array(train[:, -1])

        a = list(map(int, y))
        a = np.array(a)
        wy = np.zeros((len(train), number_of_groups))
        wy[np.arange(len(train)), a] = 1

        W = np.matmul(np.matmul(np.linalg.pinv(np.matmul(Gt, G)), Gt), wy)

        y_hat = np.matmul(G, W)
        sub = np.subtract(np.argmax(y_hat, axis=1), y)
        return 0.5 * np.matmul(np.transpose(sub), sub),
    else:
        G = []
        W = []
        V = np.array(ind[0:-number_of_groups]).reshape([number_of_groups, dimension])
        for point in train:
            g_row = []
            for group_num in range(number_of_groups):
                difference = np.array(point[:-1] - V[group_num])
                pow = -ind[number_of_groups * dimension + group_num] * (np.matmul(np.transpose(difference), difference))
                element = np.math.e ** pow
                g_row.append(element)
            G.append(g_row)
        G = np.array(G)
        W = np.array(W)
        Gt = np.transpose(G)
        y = np.array(train[:, -1])
        try:
            W = np.matmul(np.matmul(np.linalg.pinv(np.matmul(Gt, G)), Gt), y)
        except:
            W = np.random.rand((number_of_groups, number_of_groups))
        y_hat = np.matmul(G, W)
        sub = np.subtract(y_hat, y)
        return 0.5 * np.matmul(np.transpose(sub), sub),
```

این تابع بسته به آنکه برنامه برای `classification` صدا زده شود یا `regression` خروجی یک تاپل می دهد که الگوریتم تکاملی سعی در کمینه کردن آن می کند. به علت اینکه ممکن است `G` معکوس پذیر نباشد در صورت رخ دادن این اتفاق `W` ای رندوم به جا `W` غیر مجاز در نظر میگیریم. در طی نسل ها الگوریتم یاد میگیرد که کمتر این خطا را ایجاد کند.

در نهایت نیز برای آنکه بتوانیم مدل تربیت شده خود را بسنجیم آن را با داده های تست امتحان می کنیم و درصد شباهت خروجی آن را با واقعیت به وسیله تابع `accuracy` می سنجیم:

```
def accuracy(ind):
    if classification:
        G = []
        W = []
        V = np.array(ind[0:-number_of_groups]).reshape([number_of_groups, dimension])
        for point in test:
            g_row = []
            for group_num in range(number_of_groups):
                difference = np.array(point[:-1] - V[group_num])
                pow = -ind[number_of_groups * dimension + group_num] * (np.matmul(np.transpose(difference), difference))
                element = np.math.e ** pow
                g_row.append(element)
            G.append(g_row)
        G = np.array(G)
        W = np.array(W)
        Gt = np.transpose(G)
        a = np.array(test[:, -1])
        a = list(map(int, a))
```

```

a = np.array(a)
y = np.zeros((len(test), number_of_groups))
y[np.arange(len(test)), a] = 1
try:
    W = np.matmul(np.matmul(np.linalg.pinv(np.matmul(Gt, G)), Gt), y)
except:
    W = np.random.rand((number_of_groups, number_of_groups))
y_hat = np.matmul(G, W)
a = np.zeros((len(test), dimension + 1))
for i in range(len(test)):
    if test[i][-1] != np.argmax(y_hat, axis=1)[i]:
        a[i] = test[i]
green = np.full(len(test), 'green')
red = np.full(len(test), 'red')
test_all = test[:, -1] == np.argmax(y_hat, axis=1)
colors = np.where(test_all, green, red)
plot_data(test, a, V, colors, ind[-number_of_groups:])
return np.sum(test_all)
else:
    G = []
    W = []
    V = np.array(ind[0:-number_of_groups]).reshape([number_of_groups, dimension])
    for point in test:
        g_row = []
        for group_num in range(number_of_groups):
            difference = np.array(point[:-1] - V[group_num])
            pow = -ind[number_of_groups * dimension + group_num] * (np.matmul(np.transpose(difference), difference))
            element = np.math.e ** pow
            g_row.append(element)
        G.append(g_row)
    G = np.array(G)
    W = np.array(W)
    Gt = np.transpose(G)
    y = np.array(test)[:, -1]
    W = np.matmul(np.matmul(np.linalg.pinv(np.matmul(Gt, G)), Gt), y)
    y_hat = np.matmul(G, W)
    a = np.zeros((len(test), 2))
    for i in range(len(test)):
        a[i][0] = i
        a[i][1] = y_hat[i]
    b = np.zeros((len(test), 2))
    for i in range(len(test)):
        b[i][0] = i
        b[i][1] = test[i][-1]
    scatter_data(b, a)
    return y_hat

```

تنظیمات:

```

number_of_groups = 10
dimension = 2
classification = True

```

```

IND_SIZE = number_of_groups * dimension + number_of_groups
MIN_VALUE = -1
MAX_VALUE = 1
MIN_STRATEGY = 0.01
MAX_STRATEGY = 0.5

```

مقدار `number_of_groups` که در واقع نشان دهنده تعداد مرکز هاست و `dimension` که نشان دهنده ابعاد ورودی هاست، بسته به ورودی تعیین می شوند. بولین `classification` نیز بسته به اینکه سوال از جنس `classification` است یا `regression`، به ترتیب مقدار `True` و `False` می پذیرد. `Individual` size با توجه به `number of groups` و `dimension` به شکلی که گفته شد تعیین می شود. با توجه به اینکه داده های گرفته شده در ابتدا نرمال می شوند (به بازه -۱ تا ۱ مپ می شوند) `MIN_VALUE` و `MAX_VALUE`، به ترتیب -۱ و ۱ قرار داده می شود. و به همین نسبت `MIN_STRATEGY` و `MAX_STRATEGY`، ۰،۰۱ و ۰،۵ قرار داده می شوند که با توجه به چند آزمون و خطا خروجی مناسب تری داشتند. در انتها `ngen` که تعداد نسل ها است نیز با توجه به سختی مسئله و تعداد نسل های لازم برای همگرا شدن تعیین می شود.


خروجی:

در انتها نیز خروجی به شکل نمودار داده های تست با رنگ های سبز (برای نقاطی که شبکه ما به درستی آن ها را تشخیص داده) و قرمز (برای نقاطی که شبکه ما به اشتباه آن ها را تشخیص داده) به همراه درصد دقت نشان داده می شود:

مثال یک:


داده های ورودی (train.csv و test.csv):

تعداد کلاس ها: ۵



تشخیص شبکه عصبی ما:


تعداد نسل ها: ۱۵ | تعداد مرکز ها: ۱۰ | جمعیت هر نسل: ۱۰ | تعداد فرزندان هر نسل: ۱۰۰ | دقت: ۹۷,۱۹٪



مثال دو:


داده های ورودی (5clstrain1500.csv و 5clstest5000.csv):

تعداد کلاس ها: ۵



تشخیص شبکه عصبی ما:


تعداد نسل ها: ۲۰ | تعداد مرکز ها: ۱۰ | جمعیت هر نسل: ۱۰ | تعداد فرزندان هر نسل: ۱۰۰ | دقت: ۹۵,۳۷٪



مثال سه:


داده های ورودی (2clstrain1500.csv و 2clstest5000.csv):

تعداد کلاس ها: ۲



تشخیص شبکه عصبی ما:

تعداد نسل ها: ۱۰ | تعداد مرکز ها: ۱۰ | جمعیت هر نسل: ۱۰۰ | تعداد فرزندان هر نسل: ۱۰۰ | دقت: ۹۸,۶۱٪



مثال چهار:

داده های ورودی (reg.csv):




تشخیص شبکه عصبی ما:

تعداد نسل ها: ۲۰ | تعداد مرکز ها: ۱۰ | جمعیت هر نسل: ۱۰ | تعداد فرزندان هر نسل: ۱۰۰



مثال پنج:

داده های ورودی (regdata2000.csv):



تشخیص شبکه عصبی ما:

تعداد نسل ها: ۲۰ | تعداد مرکز ها: ۱۰ | جمعیت هر نسل: ۱۰ | تعداد فرزندان هر نسل: ۱۰۰

